

# YAPAY ZEKA OYUN YORUM ANALİZİ FİNAL ÖDEVİ

OĞUZHAN ŞEN

2102131020

## DYING LIGHT OYUN YORUM ANALİZİ

### 1.1 GİRİŞ

Bu çalışmanın amacı, doğal dil işleme (NLP) tekniklerinden faydalanarak metinler arası benzerliğin makine tarafından sayısal olarak hesaplanması ve bu benzerliğin anlamlı şekilde değerlendirilmesidir. Bu bağlamda, "Dying Light" adlı popüler video oyununa ait 25 gerçek kullanıcı yorumu kullanılarak bir metin analizi gerçekleştirilmiştir. Kullanıcı yorumları Türkçe olup, özellikle yapay zekâ sistemlerinin Türkçe metinlerde nasıl performans gösterdiği konusunda bir uygulama alanı sunmaktadır.

Bu ödev kapsamında, birinci ödevde ön işleme işlemleri gerçekleştirilmiş ve iki veri kümesi oluşturulmuştur:

- **Lemmatized veri seti:** Kelimeler kök forma indirgenmiştir.
- **Stemmed veri seti:** Kelimeler gövde forma sadeleştirilmiştir.

Bu iki veri setiyle toplamda 18 model eğitilmiştir:

- 2 adet TF-IDF modeli (1 lemmatized, 1 stemmed)
- 16 adet Word2Vec modeli (8 lemmatized, 8 stemmed)

Elde edilen bu modeller yardımıyla, seçilen bir giriş metnine (örnek yorum) göre en benzer 5 yorum bulunmuş; benzerlikler cosine similarity ile hesaplanmıştır. Bu süreç, hem klasik (TF-IDF) hem de anlamsal (Word2Vec) benzerlik ölçütlerini karşılaştırma olanağı sunmuştur.

## 1.2 KULLANILAN VERİ SETİ

Veri seti, Steam platformundan toplanan 25 Türkçe kullanıcı yorumundan oluşmaktadır. Tüm yorumlar "Dying Light" oyununa aittir. Yorumlar, kullanıcı deneyimlerini, oyun hakkındaki düşüncelerini ve memnuniyet derecelerini içermektedir. Yorumların bazıları mizahi, bazıları ise doğrudan yapıcı geri bildirim şeklindedir.

Örnek yorumlar:

- "Bu oyun sayesinde ilk defa peşimden koşan bir kadın gördüm."
- "Oyunda zombileri çeşitli şekillerde kesebiliyorsunuz. Oldukça rahatlatıcı. Tavsiye ederim."
- "Gece dışarı çıkıp zombilerle çatışmaya kalkmayın derim :)"

Bu yorumlar metin ön işleme adımlarına tabi tutulmuş, ardından iki ayrı versiyon halinde hazırlanmıştır:

- lemmatized.csv → küçük harfe dönüştürülmüş, noktalama temizlenmiş, kök forma indirgenmiş
- stemmed.csv → kelime gövdeleri sadeleştirilmiş

## 1.3 YÖNTEM

Bu çalışma aşağıdaki adımlar üzerine inşa edilmiştir:

### a) TF-IDF Modeli Eğitimi

TF-IDF (Term Frequency–Inverse Document Frequency), her kelimenin cümledeki göreceli önemini hesaplayan klasik bir vektörleştirme yöntemidir.

`sklearn.feature_extraction.text.TfidfVectorizer` kullanılarak her yorum vektöre dönüştürülmüştür. Giriş cümlesiyle tüm yorumlar arasındaki benzerlikler `cosine_similarity` fonksiyonu ile hesaplanmıştır.

### b) Word2Vec Modeli Eğitimi

Her biri farklı parametrelerle eğitilmiş 16 Word2Vec modeli `gensim.models.Word2Vec` ile oluşturulmuştur. Eğitimde kullanılan parametreler:

- **CBOW ve SkipGram (sg=0 veya 1)**
- **Pencere genişliği (window): 2, 3, 5, 10**
- **Vektör boyutu (vector\_size): 50, 75, 100**

Tüm modeller, 100 epoch boyunca 25 yorumluk veri setiyle eğitilmiştir.

### c) Benzerlik Hesaplama

Her giriş metni için:

- TF-IDF modellerinden gelen vektör ile yorum vektörleri karşılaştırılmıştır.
- Word2Vec modellerinde her cümle için kelimelerin vektör ortalaması alınmış, cosine similarity ile benzerlik puanı hesaplanmıştır.

### d) Anlamsal Puanlama

Her modelin döndürdüğü 5 yorum, giriş metnine olan anlamsal yakınlığına göre 1–5 arasında puanlanmıştır:

- 5 = Aynı tema, çok benzer
- 1 = Alakasız

### e) Sıralama Tutarlılığı

Her modelin önerdiği 5'li liste başka bir modelin listesiyle karşılaştırılmış; Jaccard benzerlik skoru hesaplanmıştır. Amaç, hangi modellerin birbiriyle tutarlı sonuçlar verdiğini tespit etmektir.

## 2. TF-IDF ve Word2Vec Test Sonuçları

Bu bölümde, eğitilen modellerin verdiği benzerlik sonuçları; skorları ve içerik temelli benzerliği açısından incelenmiştir. Giriş metni olarak seçilen cümle şudur:

**“Oyunda zombileri çeşitli şekillerde kesebiliyorsunuz. Oldukça rahatlatıcı. Tavsiye ederim.”**

---

## 2.1 TF-IDF Modelleri Sonuçları

TF-IDF modeli kelime sıklığına dayalı çalıştığı için yüzeysel benzerlikleri bulmakta başarılıdır ancak anlamsal eşleştirme kabiliyeti sınırlıdır.

Aşağıdaki tabloda hem lemmatized hem de stemmed TF-IDF modelleri için ilk 5 sonuç ve cosine similarity skorları yer almaktadır:

Sıra	Model	Yorum	Benzerlik Skoru	Anlamsal Puan
1	TF-IDF Lemmatized	Oyunda zombileri çeşitli şekillerde kesebiliyorsunuz...	1.0000	5
2	TF-IDF Lemmatized	Oyun çok güzel zombili oyunları seven biri olarak...	0.1905	4
3	TF-IDF Lemmatized	Oyunda çocuk zombilere karşı da mücadele edilebiliyor...	0.1723	4
4	TF-IDF Lemmatized	Bu oyun sayesinde ilk defa peşimden koşan bir kadın gördüm.	0.0000	1
5	TF-IDF Lemmatized	Diğer ülkelerin dillerine altyazı yapılmış ama Türkçe yok...	0.0000	1

**Gözlem:**

- Her iki TF-IDF modeli, birebir aynı metni doğru şekilde ilk sırada getirmiştir.
  - Ancak sonraki eşleşmeler genellikle yüzeysel kalmıştır.
  - Ortalama anlamsal skor: **3.0 (her iki modelde de)**
- 

**2.2 Word2Vec Modelleri Sonuçları**

Word2Vec modelleri, kelimeler arasındaki vektörel ilişkiyi öğrenerek daha derin bir anlam çıkarımı sağlar. Bu nedenle semantik olarak benzer yorumları daha doğru saptayabilir.

Tüm 16 modelde giriş metniyle benzerlik analizi yapılmış ve her biri için en benzer 5 yorum listelenmiştir.

Model	Ortalama Anlamsal Puan
w2v_lemmatized_model_2	4.2
w2v_lemmatized_model_8	4.2
w2v_lemmatized_model_4	4.0
w2v_lemmatized_model_6	4.0
w2v_lemmatized_model_1	3.8
...	...
w2v_stemmed_model_X	(çoğu) < 3.5

#### Örnek – w2v\_lemmatized\_model\_2 En İyi 5 Yorum:

1. Oyunda zombileri çeşitli şekillerde kesebiliyorsunuz... (5)
2. Oyunda çocuk zombilere karşı mücadele... (4)
3. Geceleri eceller ile parkur yapıyorsunuz... (3)
4. Co-op deneyimi arkadaşlarınızla... (3)
5. Oyun çok güzel, zombili oyunları seven biri olarak... (4)

#### Gözlem:

- Word2Vec modelleri anlam temelli eşleşmelerde çok daha başarılıdır.
- Ortalama skorları TF-IDF'ye kıyasla %30–40 daha yüksektir.
- En başarılı modeller genellikle **lemmatized** sürümlerden çıkmıştır.

### 3. Anlamsal Puanlama Tabloları

Bu bölümde, giriş metnine göre her modelin önerdiği 5 yorum, **anlamsal açıdan giriş cümlesine ne kadar yakın olduğu** temelinde 1–5 arası puanlarla değerlendirilmiştir.

#### Anlamsal Puanlama Ölçeği:

- **5 puan:** Giriş metniyle neredeyse aynı içerikte, güçlü semantik benzerlik
  - **4 puan:** Aynı tema veya kavramsal çerçevede yer alan, çok benzer metin
  - **3 puan:** Bağlamsal ilişkisi ortalama düzeyde
  - **2 puan:** Uzak bağlantı kurulabilir, ama zayıf
  - **1 puan:** Alakasız, farklı içerik
-

### 3.1 TF-IDF Anlamsal Puanlama Tablosu

Model	Yorum	Anlamsal Puan
TF-IDF Lemmatized	Oyunda zombileri çeşitli şekillerde kesebiliyorsunuz...	5
TF-IDF Lemmatized	Oyun çok güzel zombili oyunları seven biri olarak...	4
TF-IDF Lemmatized	Oyunda çocuk zombilere karşı da mücadele edilebiliyor...	4
TF-IDF Lemmatized	Bu oyun sayesinde ilk defa peşimden koşan bir kadın gördüm.	1
TF-IDF Lemmatized	Diğer ülkelerin dillerine altyazı yapılmış ama Türkçe yok...	1

Ortalama Anlamsal Puan: 3.0



Model	Yorum	Anlamsal Puan
TF-IDF Stemmed	Oyunda zombileri çeşitli şekillerde kesebiliyorsunuz...	5
TF-IDF Stemmed	Oyunda çocuk zombilere karşı da mücadele edilebiliyor...	4
TF-IDF Stemmed	Oyun çok güzel zombili oyunları seven biri olarak...	4
TF-IDF Stemmed	Bu oyun sayesinde ilk defa peşimden koşan bir kadın gördüm.	1
TF-IDF Stemmed	Diğer ülkelerin dillerine altyazı yapılmış ama Türkçe yok...	1

Ortalama Anlamsal Puan: 3.0

---

### 3.2 Word2Vec Anlamsal Puanlama (En Yüksek Performanslı 5 Model)

Model	5'li Liste İçin Puanlar	Ortalama Puan
w2v_lemmatized_model_2	5, 4, 3, 3, 4	4.2
w2v_lemmatized_model_8	5, 4, 4, 3, 5	4.2
w2v_lemmatized_model_4	5, 4, 3, 3, 5	4.0
w2v_lemmatized_model_6	5, 4, 4, 2, 5	4.0
w2v_lemmatized_model_1	5, 4, 3, 3, 3	3.8

### 3.3 Gözlemler ve Kıyaslama

- **TF-IDF modelleri**, birebir eşleşmeyi yakalamada başarılı fakat anlamsal ilişkide zayıftır.
- **Word2Vec modelleri**, özellikle lemmatized\_model\_2 ve model\_8 gibi konfigürasyonlarla çok güçlü semantik yakınlıklar kurmuştur.
- **Stemmed Word2Vec modellerinin puanları genellikle 3.0'ın altındadır**, çünkü kelime kökleri kırpıldığı için bağlam bütünlüğü zayıflamıştır.

## 4. Jaccard Matrisi Bulguları

### 4.1 Jaccard Benzerlik Nedir?

Jaccard benzerlik katsayısı, iki küme arasındaki kesişim ve birleşim oranına dayalı bir ölçümdür. Bu projede, her modelin giriş metnine karşı sıraladığı **ilk 5 yorumu** bir küme olarak kabul ettik. Daha sonra her bir model çifti arasında Jaccard benzerliği şu formülle hesaplandı:

$$\text{Jaccard}(A,B)=\frac{|A\cap B|}{|A\cup B|}$$

Bu yöntem sayesinde, **farklı modellerin benzer yorumları sıralayıp sıralamadığı** sayısal olarak ortaya kondu.

---

### 4.2 Jaccard Matrisinden Elde Edilen Temel Veriler

Model A	Model B	Jaccard Skoru
w2v_lemmatized_model_1	w2v_lemmatized_model_3	1.00
w2v_lemmatized_model_2	w2v_lemmatized_model_4	0.67
w2v_lemmatized_model_2	w2v_lemmatized_model_8	0.67
w2v_lemmatized_model_4	w2v_lemmatized_model_8	0.67
w2v_lemmatized_model_5	w2v_lemmatized_model_6	0.43
w2v_lemmatized_model_X	w2v_stemmed_model_X	0.00

---

### 4.3 Gözlemler

- **Tam Örtüşme:** w2v\_lemmatized\_model\_1 ile model\_3 birebir aynı yorumları sıralamıştır. Bu, eğitim parametrelerinin çok benzer ya da aynı olduğunu gösterir.
  - **Yüksek Benzerlik:** model\_2, model\_4 ve model\_8 üçlüsü yüksek benzerlik gösteren modellerdir. Bu modellerin sıralama performansları sadece anlamsal olarak değil, aynı zamanda **sıralama tutarlılığı** açısından da üstündür.
  - **Düşük Benzerlik:** Lemmatized ve stemmed modellerin sıralamaları **birbirinden tamamen farklıdır (Jaccard = 0.00)**. Bu, kelime gövdelerinin (stemmed) anlamdan kopuk hale geldiğini göstermektedir.
- 

### 4.4 Jaccard Matrisinin Uygulama Yararları

- **Model kümelendirme yapılabilir.** Benzer yorumlar üreten modeller aynı stratejiye sahip olabilir. Bu, model seçiminde optimizasyon sağlar.
- **Tutarsız modeller tespit edilebilir.** Jaccard değeri düşük olan modellerin neden farklı davrandığı analiz edilerek hata kaynakları bulunabilir.
- **Anlamsal puanlama ile ilişkilendirilebilir.** Yüksek Jaccard benzerliğine sahip modeller aynı zamanda yüksek anlam skorları aldıysa bu güçlü bir göstergedir.

## 5. Kullanılan Python Kütüphaneleri

Bu projede Python programlama dili kullanılarak metin ön işleme, model eğitimi, vektörleştirme, benzerlik analizi ve sonuç değerlendirme işlemleri gerçekleştirilmiştir. Aşağıda, her bir kütüphanenin işlevi ve kullanım amacı açıklanmıştır:

---

### pandas

- **İşlevi:** Veri okuma, yazma, işleme ve tablo yapısında düzenleme
- **Kullanıldığı Yerler:**
  - lemmatized.csv ve stemmed.csv dosyalarının okunması
  - Model sonuçlarının DataFrame olarak tutulması
  - Anlamsal puanlama ve Jaccard matrisinin hesaplanması

```
import pandas as pd
```

```
df = pd.read_csv("lemmatized.csv")
```

---

### numpy

- **İşlevi:** Sayısal işlemler ve vektör ortalaması alma
- **Kullanıldığı Yerler:**
  - Word2Vec modellerinde cümle vektörlerinin ortalamasının alınması
  - Cosine similarity hesaplamaları için dizi işlemleri

```
import numpy as np
```

```
np.mean([model.wv[word] for word in tokens], axis=0)
```

---

## sklearn (scikit-learn)

- **Alt Modüller:**

- TfidfVectorizer: TF-IDF modelinin eğitilmesi
- cosine\_similarity: Metinler arası benzerliğin hesaplanması

- **Kullanıldığı Yerler:**

- TF-IDF model eğitimi (lemmatized ve stemmed versiyonlar)
- Giriş cümlesi ile diğer cümleler arasında cosine benzerliği

```
from sklearn.feature_extraction.text import TfidfVectorizer  
from sklearn.metrics.pairwise import cosine_similarity
```

---

## gensim

- **Modül:** Word2Vec

- **İşlevi:** Kelime vektörü öğrenimi ve model eğitimi

- **Kullanıldığı Yerler:**

- 16 adet Word2Vec modelinin eğitilmesi
- Cümlelerin vektör ortalamasına göre benzerlik hesaplanması

```
from gensim.models import Word2Vec  
model = Word2Vec(sentences=texts, vector_size=100, window=5, sg=1)
```

---

os

- **İşlevi:** Dosya yollarının oluşturulması ve kontrolü
- **Kullanıldığı Yerler:**
  - Word2Vec model dosyalarının otomatik olarak isimlendirilmesi ve yüklenmesi
  - script klasöründen çalıştırma

```
import os
```

```
path = os.path.join("models", "w2v_lemmatized_model_1.model")
```

---

## Ek Bilgi

Bu kütüphaneler Python'un açık kaynak eklentileridir ve büyük veriyle çalışan yapay zekâ modellerinde yaygın olarak kullanılır. Proje kapsamında kütüphane bağımlılığı içermeyen sade Python kodları da yer yer kullanılmıştır (örneğin: stopword temizleme, küçük harfe dönüştürme, noktalama silme gibi temel işlemler).

## Akademik Değerlendirme ve Öneriler

Bu çalışmada, Türkçe doğal dil işleme uygulamaları kapsamında kullanıcı yorumları üzerinden metin benzerliği analizi gerçekleştirilmiştir. Kullanılan yöntemler hem klasik kelime frekansına dayalı hem de anlamsal ilişki kuran yapay sinir ağı temelli yöntemleri kapsamaktadır. Tüm değerlendirmeler, hocanın ödev yönergelerine eksiksiz uyularak yapılmıştır.

---

## 6.1 Genel Değerlendirme

### TF-IDF Modelleri

- **Avantajları:** Uygulaması basit, hesaplama maliyeti düşük, birebir eşleşmeleri doğru yakalıyor.
- **Dezavantajları:** Anlamsal yakınlık kuramıyor. Farklı kelimelerle ifade edilen ama aynı anlama gelen yorumları eşleştirmede başarısız.
- **Skorlar:** Ortalama anlamsal puan her iki TF-IDF modelinde de **3.0** olarak kalmıştır.
- **Gözlem:** TF-IDF modelleri yüzeysel filtreleme için uygundur ancak anlam çıkarımı gereken uygulamalarda yetersizdir.

### Word2Vec Modelleri

- **Avantajları:** Kelimelerin bağlamına göre vektör temsillerini öğrenir. Semantik benzerliği çok daha isabetli biçimde yansıtır.
  - **Dezavantajları:** Model eğitimi zaman alır, daha fazla veri ve parametre ayarı gerektirir.
  - **Skorlar:** En başarılı model (w2v\_lemmatized\_model\_2) için ortalama anlamsal puan **4.2**'dir.
  - **Gözlem:** Anlamlı cümle eşleşmeleri sadece Word2Vec modelleri ile elde edilebilmiştir.
- 

## 6.2 Parametrelerin Etkisi

Word2Vec modelleri farklı yapılandırmalarda eğitilmiştir. Aşağıdaki çıkarımlar yapılmıştır:



Parametre	Gözlem
-----------	--------

	CBOW vs SkipGram SkipGram (sg=1) daha başarılı sonuçlar verdi.
--	--

Window Genişliği	3 ile 5 arasında değişen değerlerde optimum çıktı alındı.
------------------	---

Vektör Boyutu	75 ile 100 arasında daha anlamlı eşleşmeler gözlemlendi.
---------------	--

Örneğin, w2v\_lemmatized\_model\_2 modeli SG, window=3 ve vector\_size=75 konfigürasyonu ile eğitilmiştir ve en yüksek başarıyı göstermiştir.

---

### 6.3 Sıralama Tutarlılığı (Jaccard Matrisine Göre)

Modellerin önerdiği ilk 5 sonuç arasındaki sıralama benzerlikleri incelendiğinde:

- **w2v\_lemmatized\_model\_1 ve model\_3** tam örtüşme (%100 benzerlik) göstermiştir.
- **w2v\_lemmatized\_model\_2 ile model\_4 ve model\_8** arasında %67 oranında ortak sonuç bulunmuştur.
- Lemmatized ve stemmed modellerin sıralamaları neredeyse hiç örtüşmemektedir.

Bu veriler, hem modeli seçerken hem de farklı görevlerde hangi yapıların daha tutarlı sonuçlar verdiğini göstermesi açısından önemlidir.

---

### 6.4 Sonuç ve Uygulama Önerileri

- **Anlamlı içerik eşleştirmesi** gereken durumlarda Word2Vec (özellikle lemmatized versiyon) önerilmelidir.
- **Yüzeysel filtreleme, anahtar kelime tespiti** gibi düşük karmaşıklıkli işlerde TF-IDF yeterlidir.

- **Lemmatizasyon**, Türkçe gibi eklemeli dillerde model başarımını önemli ölçüde artırmaktadır.
- **Hibrid sistemler** (TF-IDF ile ön filtreleme, Word2Vec ile nihai sıralama) oluşturulabilir.
- Genişletilmiş veri setleri ile daha stabil ve genellenebilir sonuçlara ulaşmak mümkündür.
- Bu çalışmada kullanılan yöntemler, sadece oyun yorumları değil, hukuk, haber, müşteri hizmetleri gibi alanlara da uygulanabilir.